

Федеральное государственное автономное образовательное учреждение высшего образования «Национальный исследовательский университет ИТМО»

Факультет программной инженерии и компьютерной техники
Направление подготовки: 09.03.04 - Программная инженерия, Системное и прикладное программное обеспечение

Дисциплина: Моделирование

Учебно-исследовательская работа №1
Обработка результатов измерений: статистический
анализ числовой последовательности
Вариант 210

Выполнил:
Ткачев Денис Владимирович
Группа: Р3311
ИСУ: 467727

Проверил:
Тропченко Андрей Александрович

Содержание

Цель работы	2
Исходные данные и методика	2
Статистическая обработка исходной последовательности	2
Анализ характера числовой последовательности	3
Автокорреляционный анализ	4
Гистограмма распределения частот	5
Аппроксимация закона распределения	5
Генератор случайных величин	6
Исследование сгенерированной последовательности	7
Корреляция исходной и сгенерированной последовательностей	8
Описание программной реализации	9
Вывод	9

Цель работы

Изучить методы обработки и статистического анализа результатов измерений на примере заданной числовой последовательности: оценить числовые моменты, доверительные интервалы и корреляционные свойства, подобрать аппроксимирующий закон распределения по двум начальным моментам, реализовать генератор случайных величин и сравнить сгенерированную последовательность с исходной.

Исходные данные и методика

Исходная последовательность содержит 300 положительных вещественных значений. В соответствии с заданием исследуются префиксы длиной $n = 10, 20, 50, 100, 200, 300$.

Оценка математического ожидания вычислялась как

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Несмещённая оценка дисперсии:

$$D = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2,$$

а среднее квадратическое отклонение $\sigma = \sqrt{D}$. Коэффициент вариации рассчитывался как $\nu = \sigma / \bar{x}$.

Для доверительной вероятности p полуинтервал математического ожидания определялся по формуле

$$\varepsilon_p = t_p \frac{\sigma}{\sqrt{n}},$$

где $t_{0,90} = 1,643$, $t_{0,95} = 1,960$, $t_{0,99} = 2,576$. В таблицах приведены значения полуинтервалов ε_p .

Процентное отклонение характеристики A_n от эталонной характеристики A_{300} вычислялось как

$$\delta = \frac{|A_n - A_{300}|}{|A_{300}|} \cdot 100\%.$$

Статистическая обработка исходной последовательности

Для выборки из 300 наблюдений получено: математическое ожидание **98,578**, дисперсия **7483,545**, с.к.о. **86,507**, коэффициент вариации **0,8776**.

Характеристика	10	20	50	100	200	300
Мат. ожидание	95,732	97,198	103,450	102,639	103,142	98,578
Дисперсия	1957,000	3329,459	9471,094	9155,373	8504,960	7483,545
С.к.о.	44,238	57,701	97,320	95,684	92,222	86,507
Коэффициент вариации	0,4621	0,5936	0,9407	0,9322	0,8941	0,8776
Дов. полуинтервал 0,90	22,984	21,199	22,613	15,721	10,714	8,206
Дов. полуинтервал 0,95	27,419	25,289	26,976	18,754	12,781	9,789
Дов. полуинтервал 0,99	36,036	33,237	35,454	24,648	16,798	12,866

Таблица 1. Форма 1 - характеристики заданной числовой последовательности

Характеристика	10	20	50	100	200	300
Мат. ожидание	2,89%	1,40%	4,94%	4,12%	4,63%	0,00%
Дисперсия	73,85%	55,51%	26,56%	22,34%	13,65%	0,00%
С.к.о.	48,86%	33,30%	12,50%	10,61%	6,61%	0,00%
Коэффициент вариации	47,34%	32,35%	7,20%	6,23%	1,89%	0,00%
Дов. полуинтервал 0,90	180,09%	158,33%	175,56%	91,58%	30,57%	0,00%
Дов. полуинтервал 0,95	180,09%	158,33%	175,56%	91,58%	30,57%	0,00%
Дов. полуинтервал 0,99	180,09%	158,33%	175,56%	91,58%	30,57%	0,00%

Таблица 2. Относительные отклонения характеристик от значений при $n = 300$

Из таблиц видно, что оценки при небольших объёмах выборки заметно колеблются. При увеличении n доверительные полуинтервалы уменьшаются: для $p = 0,95$ от **27,419** при $n = 10$ до **9,789** при $n = 300$. Это отражает рост точности оценки математического ожидания при увеличении числа наблюдений.

Анализ характера числовой последовательности



Рис. 1. График значений исходной числовой последовательности

График не демонстрирует устойчивого возрастания или убывания. Регулярный визуальный период также не наблюдается. Значения нерегулярно колеблются вокруг некоторого среднего уровня, встречаются отдельные крупные значения.

Автокорреляционный анализ

Автокорреляция со сдвигом k вычислялась как коэффициент корреляции Пирсона между подпоследовательностями $(x_1, \dots, x_{n-k})$ и $(x_{1+k}, \dots, x_n)$.

Сдвиг	Исходная ЧП	Сгенерированная ЧП	Различие, %
1	−0,0263	0,0319	221,5%
2	0,1411	0,0452	67,9%
3	−0,0308	−0,0831	169,6%
4	0,0579	0,0894	54,3%
5	−0,0851	−0,0192	77,4%
6	−0,0046	−0,0335	628,9%
7	0,1398	−0,0910	165,1%
8	−0,1257	0,0582	146,3%
9	−0,0563	0,0065	111,6%
10	−0,0611	0,0152	124,8%

Таблица 3. Форма 3 - коэффициенты автокорреляции




Рис. 2. Автокорреляция исходной последовательности

Для сдвигов 1-10 максимальное по модулю значение коэффициента автокорреляции исходной последовательности равно **0,1411**. Значения близки к нулю и не образуют выраженного периодического рисунка. Поэтому по результатам проведённого автокорреляционного анализа последовательность можно считать случайной в пределах исследованных сдвигов.

Гистограмма распределения частот




Рис. 3. Гистограмма распределения частот исходной последовательности

Распределение имеет правостороннюю асимметрию: большая часть наблюдений сосредоточена в области небольших значений, а справа присутствует длинный хвост с отдельными крупными наблюдениями.

Аппроксимация закона распределения

Для полной последовательности получен коэффициент вариации $\nu = 0,8776$. В условии лабораторной допускается выбор между равномерным, экспоненциальным, нормированным Эрланга, гипоекспоненциальным и гиперэкспоненциальным распределениями. Поскольку $1/\sqrt{2} < \nu < 1$, для двухмоментной аппроксимации принято двухфазное гипоекспоненциальное распределение. Нормированное распределение Эрланга 2-го порядка дало бы коэффициент вариации 0,707 и не совпало бы с исходным.

Модель представлена суммой двух независимых экспоненциальных фаз:

$$X = X_1 + X_2,$$

где X_1 имеет математическое ожидание t_1 , а X_2 - математическое ожидание t_2 .

Параметры определены из условий совпадения первых двух моментов:

$$t_1 + t_2 = \bar{x}, \quad t_1^2 + t_2^2 = D,$$

откуда

$$t_{1,2} = \frac{\bar{x}}{2} \left(1 \pm \sqrt{2\nu^2 - 1} \right).$$

Получены параметры:

- $t_1 = 85,516$, $\lambda_1 = 1/t_1 = 0,011694$.
- $t_2 = 13,063$, $\lambda_2 = 1/t_2 = 0,076553$.
- Теоретическое математическое ожидание модели совпадает с **98,578**.

- Теоретическая дисперсия совпадает с **7483,545**.

Плотность распределения модели:

$$f(x) = \frac{e^{-x/t_1} - e^{-x/t_2}}{t_1 - t_2}, \quad x \geq 0.$$




Рис. 4. Сравнение гистограммы исходной ЧП и плотности аппроксимирующего закона

Плотность гипотетического закона воспроизводит общий вид эмпирической гистограммы: максимум в области небольших значений и убывающий правый хвост. Точное совпадение не ожидается, так как параметры подбирались только по двум числовым моментам.

Генератор случайных величин

Генератор реализован на Python. Для каждого значения формируются две независимые экспоненциальные величины со средними t_1 и t_2 методом обратной функции, после чего они суммируются:

$$X = -t_1 \ln(1 - r_1) - t_2 \ln(1 - r_2),$$

где r_1, r_2 - независимые равномерно распределённые на $[0; 1)$ случайные числа.

```
def hypoexp_generate(t1, t2, size, rng):
    r1, r2 = rng.random(size), rng.random(size)
    return -t1 * np.log(1 - r1) - t2 * np.log(1 - r2)
```

Для воспроизводимости используется фиксированное начальное состояние генератора `seed = 42`. Получено 300 значений, сохранённых в файле `output/generated.txt`.

Исследование сгенерированной последовательности

Характеристика	10	20	50	100	200	300
Мат. ожидание	118,971	108,637	102,788	88,945	93,382	92,912
Дисперсия	8285,132	6163,983	6113,865	4657,841	5702,752	5817,279
С.к.о.	91,023	78,511	78,191	68,248	75,517	76,271
Коэффициент вариации	0,7651	0,7227	0,7607	0,7673	0,8087	0,8209
Дов. полуинтервал 0,90	47,292	28,844	18,168	11,213	8,773	7,235
Дов. полуинтервал 0,95	56,416	34,409	21,673	13,377	10,466	8,631
Дов. полуинтервал 0,99	74,147	45,223	28,485	17,581	13,755	11,343

Таблица 4. Форма 2 - характеристики сгенерированной случайной последовательности

Характеристика	10	20	50	100	200	300
Мат. ожидание	24,28%	11,77%	0,64%	13,34%	9,46%	5,75%
Дисперсия	323,36%	85,13%	35,45%	49,12%	32,95%	22,27%
С.к.о.	105,76%	36,06%	19,66%	28,67%	18,11%	11,83%
Коэффициент вариации	65,56%	21,74%	19,14%	17,69%	9,56%	6,46%
Дов. полуинтервал 0,90	105,76%	36,06%	19,66%	28,67%	18,11%	11,83%
Дов. полуинтервал 0,95	105,76%	36,06%	19,66%	28,67%	18,11%	11,83%
Дов. полуинтервал 0,99	105,76%	36,06%	19,66%	28,67%	18,11%	11,83%

Таблица 5. Относительные отклонения от одноимённых характеристик исходной ЧП

Для $n = 300$ сгенерированная последовательность имеет математическое ожидание **92,912**, дисперсию **5817,279**, с.к.о. **76,271** и коэффициент вариации **0,8209**. Отклонение математического ожидания от исходной ЧП составляет **5,75%**, дисперсии - **22,27%**, с.к.о. - **11,83%**, коэффициента вариации - **6,46%**.



Рис. 5. Сравнение исходной и сгенерированной последовательностей




Рис. 6. Сравнение гистограмм исходной и сгенерированной последовательностей




Рис. 7. Сравнение коэффициентов автокорреляции

Максимальный по модулю коэффициент автокорреляции сгенерированной последовательности на сдвигах 1-10 равен **0,0910**. Как и у исходной последовательности, устойчивой зависимости между соседними значениями не обнаружено.

Процентные различия коэффициентов автокорреляции в форме 3 могут принимать большие значения, потому что сами коэффициенты исходной последовательности очень близки к нулю. Поэтому для интерпретации важнее абсолютные значения коэффициентов, а не их относительное различие.

Корреляция исходной и сгенерированной последовательностей

Коэффициент корреляции Пирсона между двумя последовательностями равен

$$r = -0,006073.$$

Значение близко к нулю. Это ожидаемо: сгенерированная последовательность должна воспроизводить статистические свойства исходного распределения, но не конкретный порядок исходных наблюдений.

Описание программной реализации

Программа `main.py` выполняет лабораторную работу автоматически:

1. Считывает 300 исходных значений из `210_variant.txt`.
2. Рассчитывает математическое ожидание, дисперсию, с.к.о., коэффициент вариации и доверительные полуинтервалы для выборок 10, 20, 50, 100, 200 и 300.
3. По математическому ожиданию и коэффициенту вариации выборки из 300 значений определяет параметры гипоекспоненциальной модели.
4. Генерирует 300 новых случайных значений и сохраняет их в `output/generated.txt`.
5. Повторяет расчёт характеристик для сгенерированной ЧП.
6. Рассчитывает автокорреляцию обеих последовательностей для сдвигов 1-10.
7. Рассчитывает взаимную корреляцию исходной и сгенерированной последовательностей.
8. Вычисляет относительные отклонения и сохраняет таблицы форм 1-3 в LaTeX.
9. Строит графики последовательностей, гистограмм, плотности и автокорреляций в PNG.
10. Сохраняет численные результаты в JSON.

Вывод

В ходе работы я исследовал числовую последовательность из 300 наблюдений. Для неё я получил оценки математического ожидания **98,578**, дисперсии **7483,545**, среднеквадратического отклонения **86,507** и коэффициента вариации **0,8776**. Увеличение объёма выборки в целом приводит к стабилизации оценок и уменьшению доверительных полуинтервалов.

Графический и автокорреляционный анализ не выявили тренда, выраженной периодичности или существенной зависимости между соседними значениями на сдвигах 1-10. Для аппроксимации по двум моментам я выбрал двухфазное гипоекспоненциальное распределение с параметрами $t_1 = 85,516$ и $t_2 = 13,063$.

Реализованный генератор сформировал новую последовательность из 300 значений. Её основные числовые характеристики близки к характеристикам исходной: отклонение математического ожидания составляет **5,75%**, коэффициента вариации - **6,46%**. Корреляция между исходной и сгенерированной последовательностями равна **-0,006073**, то есть практически отсутствует. Полученная модель в целом воспроизводит основные статистические свойства исходной последовательности и может использоваться как её двухмоментная вероятностная аппроксимация.